

# Proyecto Final, P-modes

Oscar Andres Calvo Rebellon<sup>1</sup>

<sup>1</sup>Universidad Nacional de Colombia. Facultad de Ciencias-Astronomía.

## Resumen

En este proyecto se presenta el procesamiento y análisis de datos solares enfocados en la detección de modos p observados en imágenes de alta resolución. Se trabajó sobre una región cercana al centro del disco solar, utilizando un intervalo de observación de 5 horas. Para garantizar la coherencia temporal y espacial, las imágenes fueron alineadas usando una mancha solar como referencia. Posteriormente, se aplicó un filtrado en el espacio de Fourier con el fin de atenuar los modos p y separar distintas componentes de la señal. Finalmente, se entrenó una red neuronal para aprender a replicar este proceso de filtrado a partir de los datos originales. Los resultados aún no son completamente satisfactorios y requieren ajustes adicionales, o una red más compleja.

**Palabras Claves:** *p-modes, redes neuronales, trasformada de Fourier.*

## 1. Introducción

Desde la década de 1960, los astrónomos empezaron a detectar unas oscilaciones en la superficie del sol con periodos de cinco minutos aproximadamente, a partir de este descubrimiento inicia una nueva rama de estudio llamado helioseismología.




Figura 1: Mapa global de velocidades sobre la superficie solar, mostrando p-modes detectadas en la fotosfera. Las zonas rojas y azules indican desplazamientos en direcciones opuestas, revelando el patrón complejo de las ondas atrapadas en el interior solar. Extraída de [9]

La helioseismología permite estudiar las capas más profundas del sol por medio de estas mismas ondas que se propagan en su interior y se manifiestan por medio de desplazamientos periódicos observados en la fotosfera [4]. Con el tiempo, se dio a entender por los estudios e investigaciones realizadas que, las oscilaciones corresponden a modos acústicos que están atrapados.




Figura 2: Mapa de rotación diferencial solar obtenido mediante análisis helioseismológico. Los colores indican la velocidad de rotación desde el ecuador (zona amarilla/roja, más rápida) hasta los polos (zona azul, más lenta), evidenciando la estructura interna del movimiento solar. Extraída de [9]

Estas oscilaciones superficiales, conocidas como modos de presión o p-modes, estas ondas se generan dado a perturbaciones que se dan en la zona convectiva del Sol y estas se propagan por debajo de la superficie solar. La propagación de estos modos se da a determinadas condiciones físicas del interior solar, como la densidad y temperatura. Allí, las ondas acústicas pueden quedar atrapadas largos períodos, que quedan entre la fotosfera y capas más internas, esto genera patrones estacionarios observables como desplazamientos periódicos en la superficie solar [3].

Los p-modes se caracterizan por tener frecuencia, grado angular y número radial, estos parámetros que determinan la profundidad de penetración y la geometría espacial. su distribución angular permite explorar tanto regiones próximas a la superficie como zonas profundas del interior solar. Mediante el análisis detallado de estos modos y la aplicación de técnicas inversas, es posible inferir perfiles internos de temperatura, composición, velocidad del sonido y dinámica solar en re-

giones que, serían inaccesibles a la observación directa [7, 1].



Figura 3: Representación tridimensional de la superficie solar distorsionada por la superposición de p-modes. Extraída de [9]

Durante el descubrimiento de los p-modes a la actualidad, el desarrollo tecnológico ha sido de vital importancia para la investigación de la heliosesmología como ciencia. Proyectos y misiones espaciales como el SOHO (Solar and Heliospheric Observatory) y el SDO (Solar Dynamics Observatory), han podido realizar más observaciones y registrar más oscilaciones con mucho más precisión y continuidad, permitiendo obtener más información con respecto a la estructura y dinámica interna del sol [8].

El estudio de los p-modes ha permitido perfeccionar modelos que han sido clave para resolver problemas, estudiar fenómenos como la rotación diferencial y ciclos magnéticos solares. En la actualidad, investigar los p-modes requiere combinar técnicas clásicas, como la transformada de Fourier, con métodos modernos de procesamiento de datos. Es esencial realizar un alineamiento preciso de las imágenes solares, filtrar correctamente las señales captadas y emplear redes neuronales para recuperar detalles relevantes en los datos observacionales. Gracias a estos procedimientos y al gran volumen de información obtenido mediante instrumentos espaciales, es posible ampliar nuestro conocimiento sobre el comportamiento interno del Sol. Esto incluye comprender cómo ocurre el transporte de energía y cómo las interacciones magnetohidrodinámicas influyen en la actividad y evolución de nuestra estrella [2, 6, 5, 10].

## 2. Metodología

Se seleccionó una ventana de observación de cinco horas, de el 9 de mayo de 2025 a las 16:59:08 UTC hasta las 21:59:08 UTC, empleando la serie `hmi.Ic_45s` con una cadencia de 45 s (ver Fig. 4).




Figura 4: HMI Continuum

La región de interés se definió próxima al centro del disco solar en coordenadas helioproyectivas: vértice inferior izquierdo en  $(-300'', -300'')$  y vértice superior derecho en  $(200'', 200'')$ . Dado que  $\mu = \cos \theta_h \approx 1$  en esa área, no fue necesario aplicar correcciones por proyección, siendo  $\theta_h$  el ángulo heliocéntrico. Asimismo, la duración limitada de la secuencia descarta la necesidad de corregir por la rotación solar, y al tratarse de un instrumento en órbita no existen degradaciones por **seeing** ni variaciones de orientación entre planos de imagen. Se realizó un alineamiento de imágenes mediante correlación cruzada, centrando todas las imágenes con respecto a la primera de la secuencia. Para ello, se utilizó el paquete **image registration**, el cual permite calcular de manera eficiente los desplazamientos relativos entre pares de imágenes (ver Fig 5).




Figura 5: Recorte de menor tamaño utilizado para el proceso de alineamiento entre imágenes. La estructura de la mancha solar se destaca como referencia principal para asegurar una alineación precisa.

El método se basa en la correlación cruzada en el espacio de Fourier, donde el desplazamiento óptimo entre dos imágenes se obtiene al identificar el máximo de la función de correlación. En lugar de limitarse a desplazamientos enteros (de paso entero en píxeles), el algoritmo implementa una interpolación del pico de correlación en el dominio de Fourier. Esto se logra analizando la relación de fase entre las transformadas de Fourier de las imágenes, permitiendo estimar el desplazamiento con precisión subpíxel.

Para garantizar una referencia estable en el alineamiento, se seleccionó una pequeña mancha solar ubicada en el campo de visión en el sur-oeste. Esta estructura persistente permitió identificar de forma robusta los desplazamientos relativos a lo largo de la secuencia temporal y alinear cada imagen con respecto a la primera del conjunto.

Para poder restaurar la información importante inicial del filtrado de Fourier, se implementó una red neuronal convolucional tridimensional, el cual es un modelo que aprende la relación entre los cubos de entrada y los originales, y, aprovecha la estructura espacial y temporal de estos datos.

Para el caso del filtrado de p-modes se hace uso del caso tradicional como objetivo (ver sección 3.1).

El método de la red neuronal parte de la extracción de señales temporales individuales desde ambos cubos: el original sin filtrar y el filtrado. Para ello se toman muestras aleatorias en el espacio (coordenadas  $x$ ,  $y$ ) y se extraen ventanas temporales de longitud fija (150 pasos temporales), de modo que la red reciba como entrada la señal original y aprenda a devolver la versión correspondiente ya filtrada. Esta estrategia tiene varias ventajas. Por un lado, permite construir un conjunto de entrenamiento grande y variado, lo cual es esencial para que el modelo generalice bien. Por otro lado, trabajar con señales 1D por píxel mantiene el problema computacionalmente manejable, ya que el entrenamiento con bloques 3D o incluso 2D de espacio-tiempo implicaría un consumo de memoria mucho mayor.

El modelo neuronal consiste en una red secuencial simple con tres capas densas completamente conectadas. La entrada es una señal de 150 valores (la serie temporal de un píxel), y se proyecta primero a una dimensión intermedia de 64 unidades con una activación ReLU. Se repite una segunda capa oculta idéntica y finalmente se utiliza una tercera capa lineal (sin función de activación) que devuelve una señal también de longitud 150. Esta arquitectura puede considerarse un autoencoder modificado, pero en lugar de reconstruir la misma señal de entrada, reconstruye una versión modificada (filtrada). El uso de activaciones ReLU en las capas ocultas permite que el modelo aprenda relaciones no lineales entre la señal original y la señal deseada, al tiempo que evita problemas como la saturación de los gradientes que ocurren con activaciones sigmoideas.

La función de pérdida utilizada es el error cuadrático medio (MSE), lo cual tiene sentido porque el objetivo es una regresión pura: se busca que cada punto de

la señal filtrada predicha se acerque lo más posible al correspondiente punto en la señal real filtrada. El optimizador escogido es Adam, una variante del descenso de gradiente que combina la velocidad de Adagrad con la estabilidad de RMSProp, muy apropiado para problemas de aprendizaje profundo y datos ruidosos. El modelo se entrena durante 200 épocas.

## 3. Resultados

### 3.1. Preparación de datos

Se utiliza un código tradicional para eliminar los movimientos globales que pueden dificultar la observación de oscilaciones locales o, en nuestro caso, suprimir un tipo de ruido global asociado a las oscilaciones de 5 minutos.

Este tipo de filtrado es esencial cuando se desea analizar con precisión fenómenos solares de evolución lenta, como el movimiento de estructuras magnéticas o la dinámica de puntos umbrales, sin que las oscilaciones acústicas de alta frecuencia introduzcan artefactos o enmascaren las señales físicas locales.

Al aplicar la transformada de Fourier sobre las tres dimensiones del cubo de datos, la información se trasladada al espacio de frecuencias, lo que permite analizar cómo se distribuyen las componentes en función de su frecuencia espacial y temporal. En este espacio, se puede determinar la velocidad de fase de cada componente mediante la relación:

$$v_{\phi} = \frac{\omega}{\sqrt{k_x^2 + k_y^2}}.$$

A partir de esta expresión, se construye una máscara tridimensional que permite el paso únicamente de las componentes cuya velocidad de fase cumpla  $v_{\phi} \leq v_{ph}$ , donde  $v_{ph}$  es un umbral elegido (en nuestro caso, 4 km/s). Esto define una región cónica alrededor del origen en el espacio de Fourier, que actúa como un filtro paso bajo en velocidad de fase.

Una vez construida, la máscara se aplica al cubo transformado mediante multiplicación punto a punto, eliminando así las señales con velocidades de fase superiores al umbral.

Finalmente, se aplica la transformada de Fourier inversa para obtener un cubo filtrado en el dominio real ( $x, y, t$ ), en el que se han eliminado las oscilaciones rápidas. Este cubo resultante resalta las señales lentas y coherentes, fundamentales para el estudio de la dinámica solar, como la evolución estructural de las manchas, los movimientos de la penumbra o la convección en la fotosfera.

En la figura 7 se observa que, en el espacio de las frecuencias, las oscilaciones de alta frecuencia se atenúan, mientras que se conservan aquellas de baja frecuencia. Es decir, el filtrado suprime señales rápidas asociadas a los modos acústicos, permitiendo resaltar variaciones más lentas vinculadas a procesos locales.

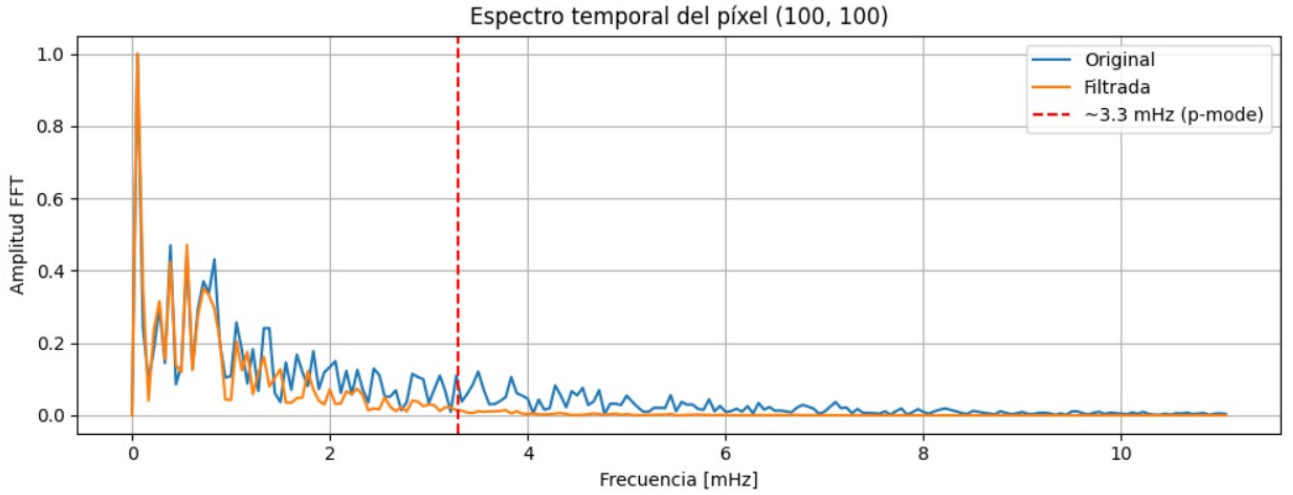


Figura 6: Ejemplo del efecto del filtrado subsónico en el espacio de frecuencias para un píxel específico.

### 3.2. Aplicación de red neuronal

Como se menciono anteriormente, se entrenó una red neuronal completamente conectada con el objetivo de replicar el filtrado de modos  $p$  aplicado a señales temporales individuales. Para ello, se extrajeron 10,000 señales correspondientes a la evolución temporal de píxeles individuales (de longitud 150 puntos) a partir de un cubo solar previamente filtrado. Cada señal original (sin filtrar) se usó como entrada, y su versión filtrada mediante técnicas en el espacio de Fourier fue empleada como objetivo (target). El conjunto de datos se dividió en un 80 % para entrenamiento y 20 % para prueba.

Al finalizar el entrenamiento, la red alcanzó una pérdida en el conjunto de prueba de aproximadamente  $1.85 \times 10^{-4}$ , indicando que fue capaz de aprender con precisión la transformación de la señal inducida por el filtrado. Esto demuestra que incluso una arquitectura sencilla puede capturar la dinámica del filtrado subsónico si se entrena adecuadamente con suficientes ejemplos individuales.

Una vez completado el entrenamiento, se seleccionó el modelo con menor pérdida en el conjunto de validación. Este modelo se extrapoló a un parche más amplio del cubo de datos solares, con dimensiones  $(T, H, W) = (150, 200, 200)$ , correspondiente a 150 instantes de tiempo y una región espacial de  $200 \times 200$  píxeles.

Para aplicar la red neuronal, el cubo tridimensional se reorganizó como una matriz bidimensional de señales temporales individuales. Específicamente, se reordenó la matriz de forma que cada fila representara la evolución temporal de un solo píxel, obteniendo un arreglo de forma  $(N, T) = (40000, 150)$ , donde  $N = H \times W$  es el número total de píxeles en el parche.

Cada una de estas señales se normalizó individualmente, sustrayendo su media y dividiendo por su desviación estándar. Esto asegura que la red neuronal reciba entradas con características similares a las vistas durante el entrenamiento. Luego, se utilizaron estas señales normalizadas como entrada para el modelo entrenado, realizando la predicción en lotes de 512 muestras

para optimizar el rendimiento computacional.

Finalmente, las señales predichas fueron reorganizadas nuevamente en la forma original del cubo, reconstruyendo un arreglo de forma  $(T, H, W) = (150, 200, 200)$ . Este volumen representa la versión filtrada del parche espacio-temporal completo, obtenida a partir del aprendizaje previo sobre señales individuales.

En la Figura mostrada, el panel superior está compuesto por tres imágenes correspondientes al mismo instante temporal de un parche de datos solares: a la izquierda se presenta la imagen original, en el centro la imagen filtrada mediante una técnica de Fourier, y a la derecha la imagen reconstruida por una red neuronal entrenada para imitar ese filtrado. En cada uno de los tres paneles se ha marcado el mismo píxel (con colores azul, naranja y verde respectivamente), donde se analiza la señal temporal.

En el panel inferior, se muestra la transformada de Fourier temporal para el píxel marcado en las tres versiones del cubo. Específicamente, se grafican las amplitudes normalizadas de la transformada de Fourier para: la señal original, la señal filtrada (Fourier) y la señal reconstruida por la red neuronal. Además, se incluye una línea vertical punteada en rojo que indica la frecuencia de aproximadamente 3.3 mHz, correspondiente a los modos acústicos solares conocidos como  $p$ -modes.

Se puede observar que el intento de usar una red neuronal no fue exitoso en replicar el efecto del filtro de Fourier. Mientras que la señal filtrada muestra una clara atenuación de las componentes de baja frecuencia —lo esperado tras un filtrado temporal—, la reconstrucción realizada por la red neuronal no logra replicar esta supresión, y en su lugar introduce nuevas componentes espectrales, como se evidencia en el espectro (línea verde punteada) que contiene picos adicionales.

En lugar de mejorar o imitar el filtrado deseado, la red neuronal parece haber introducido ruido adicional en la señal. Esto se refleja tanto en la imagen reconstruida (panel superior derecho), que visualmente conserva el ruido original, como en el espectro (panel inferior), donde se observan fluctuaciones significativas



en frecuencias que ya habían sido atenuadas por el filtro de Fourier. En resumen, este resultado evidencia que, bajo la configuración actual, la red neuronal no solo fa-

lla en su tarea de emular el filtrado temporal, sino que además degrada la señal al amplificar componentes no deseadas.

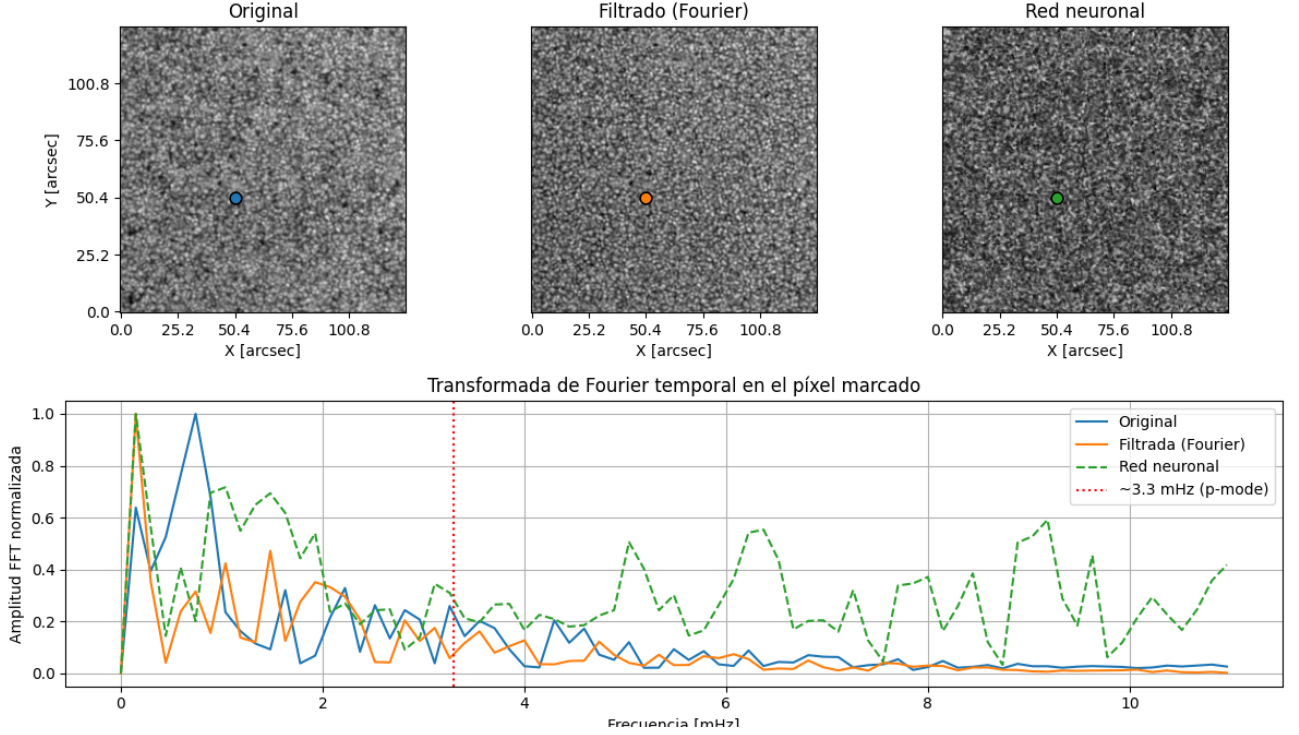


Figura 7: Comparación entre las señales originales (sin filtrar) y las señales procesadas por la red neuronal densa entrenada. Se observa que el modelo logra aproximar la forma general de la señal filtrada, aunque algunas oscilaciones de alta frecuencia persisten.

## 4. Conclusiones

En este trabajo se logró implementar un pipeline completo de alineamiento, filtrado y análisis de datos solares con el objetivo de estudiar los modos p. El uso de una mancha solar como punto de referencia permitió estabilizar la secuencia temporal, asegurando que las variaciones observadas se debieran mayoritariamente a fenómenos físicos y no a desplazamientos sistemáticos. El filtrado en el espacio de Fourier fue clave para separar las componentes de alta frecuencia asociadas a los modos p, generando así una versión depurada del cubo que sirvió como referencia para entrenar un modelo de red neuronal. Aunque no se empleó una red convolucional 3D, se utilizó una arquitectura densa que procesó bloques espacio-temporales con el fin de replicar el comportamiento del filtro aplicado. El desempeño general no fue completamente satisfactorio, lo que evidencia la necesidad de explorar arquitecturas más robustas, optimizar la selección del conjunto de entrenamiento y refinar la normalización de los datos. A pesar de estas limitaciones, el estudio muestra el potencial del aprendizaje automático como herramienta complementaria para el análisis de oscilaciones solares, especialmente en contextos donde el volumen de datos hace inviable la aplicación de métodos tradicionales de filtrado.

Una de las principales causas que podría explicar la

falla de la red neuronal es el enfoque inicial basado en un único píxel, sin considerar la información espacial circundante. Este método ignora la coherencia espacial de los modos p, que se manifiestan como patrones oscilatorios extendidos en la superficie solar. Una estrategia más adecuada consistiría en comparar ventanas o parches espacio-temporales, permitiendo que la red neuronal interprete estas estructuras de manera más robusta. Sin embargo, esta aproximación requiere redes convolucionales 2D o 3D más complejas, lo que implica un mayor costo computacional. Además, las variaciones en la intensidad debidas a la convección (como los granos solares) y la presencia de regiones con campos magnéticos intensos introducen caídas abruptas en la señal, que dificultan la identificación de los modos p si se analiza únicamente cada píxel por separado. Por ello, una alternativa más efectiva podría ser el análisis por regiones, donde se tenga en cuenta tanto la información espacial como la frecuencia, para lograr una supresión más precisa del ruido y una mejor recuperación de las oscilaciones solares.

Además, no basta con analizar únicamente la variación de intensidad en cada píxel, ya que las oscilaciones solares (particularmente los modos p) no solo implican cambios locales, sino también deformaciones que se propagan dentro y fuera del plano de observación. Estas oscilaciones afectan la estructura global del campo de intensidad y su distribución en el tiempo,

por lo que es fundamental considerar cómo se modifican las relaciones espaciales y temporales en toda la región observada. Un análisis más completo debería incorporar esta información estructural para mejorar la

capacidad de la red neuronal en distinguir y recuperar adecuadamente los patrones de oscilación, más allá de lo que puede ofrecer un enfoque estrictamente puntual.

## Referencias

- [1] A. C. Birch and A. G. Kosovichev. The interpretation of helioseismic travel times. *Solar Physics*, 192:193–201, 2000.
- [2] W. J. Chaplin and S. Basu. Solar oscillations and the solar cycle. *Solar Physics*, 251:53–65, 2008.
- [3] J. Christensen-Dalsgaard. Helioseismology. *Astronomy & Astrophysics*, 2001.
- [4] J. Christensen-Dalsgaard. Helioseismology. *Reviews of Modern Physics*, 74:1073–1129, 2002.
- [5] R. A. García et al. Line profile analysis of solar oscillations. *Astronomy & Astrophysics*, 379:622–629, 2001.
- [6] R. Howe. Solar interior rotation and its variation. *Living Reviews in Solar Physics*, 6:1, 2009.
- [7] A. G. Kosovichev. Advances in global and local helioseismology: An introductory review. *Seismological Research Letters*, 82(3):416–423, 2011.
- [8] NASA. Sdo (solar dynamics observatory) mission overview. <https://sdo.gsfc.nasa.gov/mission/instruments.php>.
- [9] NASA Marshall Space Flight Center. Helioseismology. <https://solarscience.msfc.nasa.gov/Helioseismology.shtml>.
- [10] J. Schou et al. Helioseismic studies of differential rotation in the solar envelope by the solar oscillations investigation using the michelson doppler imager. *The Astrophysical Journal*, 505(1):390–417, 1998.